BEAT 프로젝트 결과 발표 · v2

BCI 전송물의 신원 노출과 방어 효과는 공격자가 어느 날의 기록으로 등록하느냐에 따라 달라지므로, 같은 날 수치 하나로는 위험도 보호도 주장할 수 없다

근거: 자체 핵심 수치(같은 날 0.994, 다른 날 0.520), 자체 방어 EQ, 그리고 새 사용자 51명에 대한 시각 인증 사전등록

BEAT 팀 · 이동현 · 장규범

2026년 11월 16일

문제

BCI는 해독 결과를 밖으로 보내고, 공격자는 그 전송물로 사용자를 맞힌다



얼마나 새는가

특징 벡터와 명령에서 사용자 신원이 얼마나 드러나는가

줄일 수 있는가

왼손·오른손 해독 성능을 지키면서 노출을 낮출 수 있는가

어느 날로 등록하는가

공격자가 같은 날 기록으로 등록할 때와 다른 날 기록으로 등록할 때, 위험과 보호의 답이 같은가

데이터와 봉인

공개 데이터 세 종으로 분석하고, 각 분석의 채점 전에 네 번 봉인했다

BCI IV 2a

9명 · 22채널 · 253차원

서로 다른 날 두 세션

탐색과 1차 확증 (봉인 1–2)

Lee2019/OpenBMI

54명 · 20채널 · 210차원

서로 다른 날 두 세션

확증 재현 C1–C4 (봉인 3)

Yang2025 (WBCIC-SHU)

51명 · 19채널 · 190차원

3일, 하루 200시행

다른 날 재현 M1–M3 (봉인 4)

봉인 1–3 · 자기 증명

프로젝트가 만든 Git 태그다. 언제 만들었는지는 제3자가 증명하지 않는다

봉인 4 · 시각 인증

FreeTSA RFC 3161 토큰, 토큰 시각 2026-11-10 20:26:22 GMT

CI 검증

`python -m beat.verify --seals` 가 봉인 뒤 변경을 검사한다

지표: 신원 balanced accuracy, 우연 수준 = 1/사용자 수 (9명 0.111, 54명 0.019, 51명 0.020). 공격자는 방어를 고정한 뒤 그 출력만으로 따로 학습한다

가공하지 않은 특징은 같은 날 0.994, 다른 날 0.520으로 사용자를 식별한다

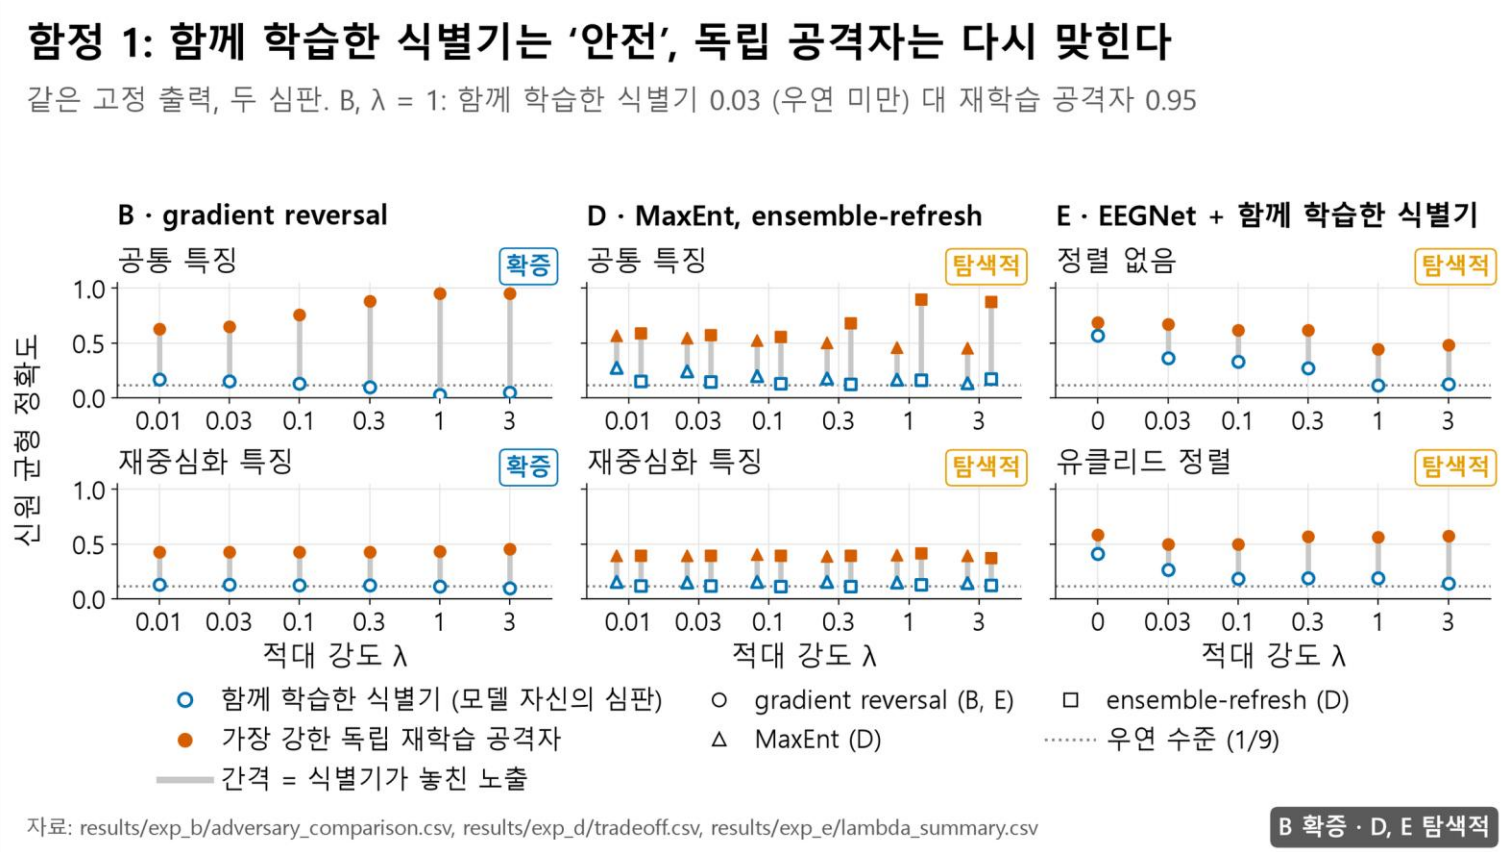
	같은 날 — 세션 2 안에서 등록하고 공격	다른 날 — 세션 1로 등록, 세션 2 공격
전체 특징 (P0) 210차원 접공간 벡터, 방어 없음	**0.994** 확증 C2의 기준값	**0.520** 사전등록 추정치
재중심화 병목 (P2-RC) 과제 정보만 남긴 d = 8 표현	**0.340** 확증 C2	**0.054** 사전등록 추정치

C2 확증 (같은 날): 0.994 → 0.340, 과제 정확도 변화 −0.6%p (하한 −2.3%p, 허용 한계 −5%p), Holm $p = 4.6 \times 10^{-5}$

가장 강한 독립 공격자의 값, 우연 수준 0.019. BCI IV 2a 9명은 22채널 253차원이며 같은 날 1.00

함정 1 · 함께 학습한 식별기

방어와 함께 학습한 식별기는 안전하다고 말하지만, 독립 공격자는 다른 날에도 다시 맞힌다



같은 날 **확증 (B)**

BCI IV 2a 9명, λ = 1

0.026 대 0.951

함께 학습한 식별기 대 독립 공격자

확증 C1

Lee2019 54명, λ = 1

0.040 대 0.514

공격자 0.514는 같은 날 값
식별기 0.040은 세션 1 학습·세션 2 채점 단일 값
Holm p = 8.9×10^{-26}

다른 날 **사전등록 추정치**

Lee2019 54명, 세션 1로 등록

0.040 대 0.239

격차 19.9%p가 남는다

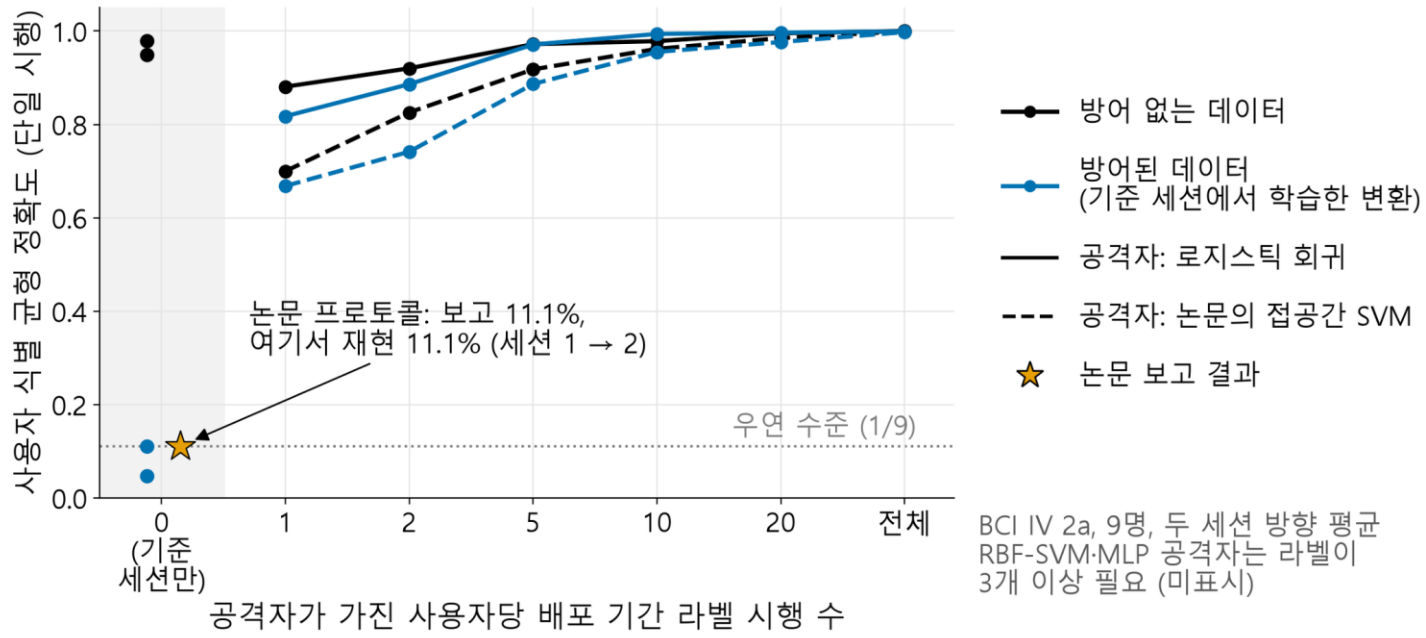
다른 날 **확증 판정 M2**

새 51명: 격차 0.093–0.096이 봉인한 하한 0.10 미만 → **M2 지지 안 됨**
(1일차 같은 날 격차는 0.717)

기준 세션 공격자만으로 시험한 방어는, 같은 날 배포 라벨 몇 개로 다시 뚫린다

함정 2: 기준 세션 공격자로만 시험한 방어

공개 방어는 재현되지만(11.1%), 사용자당 배포 기간 라벨 1개로 82%, 5개로 97%가 다시 식별된다



BCI IV 2a, 9명, 두 세션 방향 평균
RBF-SVM·MLP 공격자는 라벨이 3개 이상 필요 (미표시)

자료: results/exp_g/bnci/enrolment_averaged.csv, identity_averaged.csv, paper_table1_comparison.csv

탐색적

논문이 틀렸다는 뜻이 아니다. 공격자가 어느 날의 라벨을 갖느냐에 따라 보호 결론이 뒤집힌다

다른 날 탐색

arXiv 2610.15626 재현, 2a 9명

90.8% → 11.1%

사전공개 논문
기준 세션 라벨만 가진 공격자

같은 날 탐색

배포 기간 라벨, 사용자당 (2a 9명)

1개 81.75%
5개 97.11%

다른 날 → **같은 날** 확증 C4

Lee2019 54명

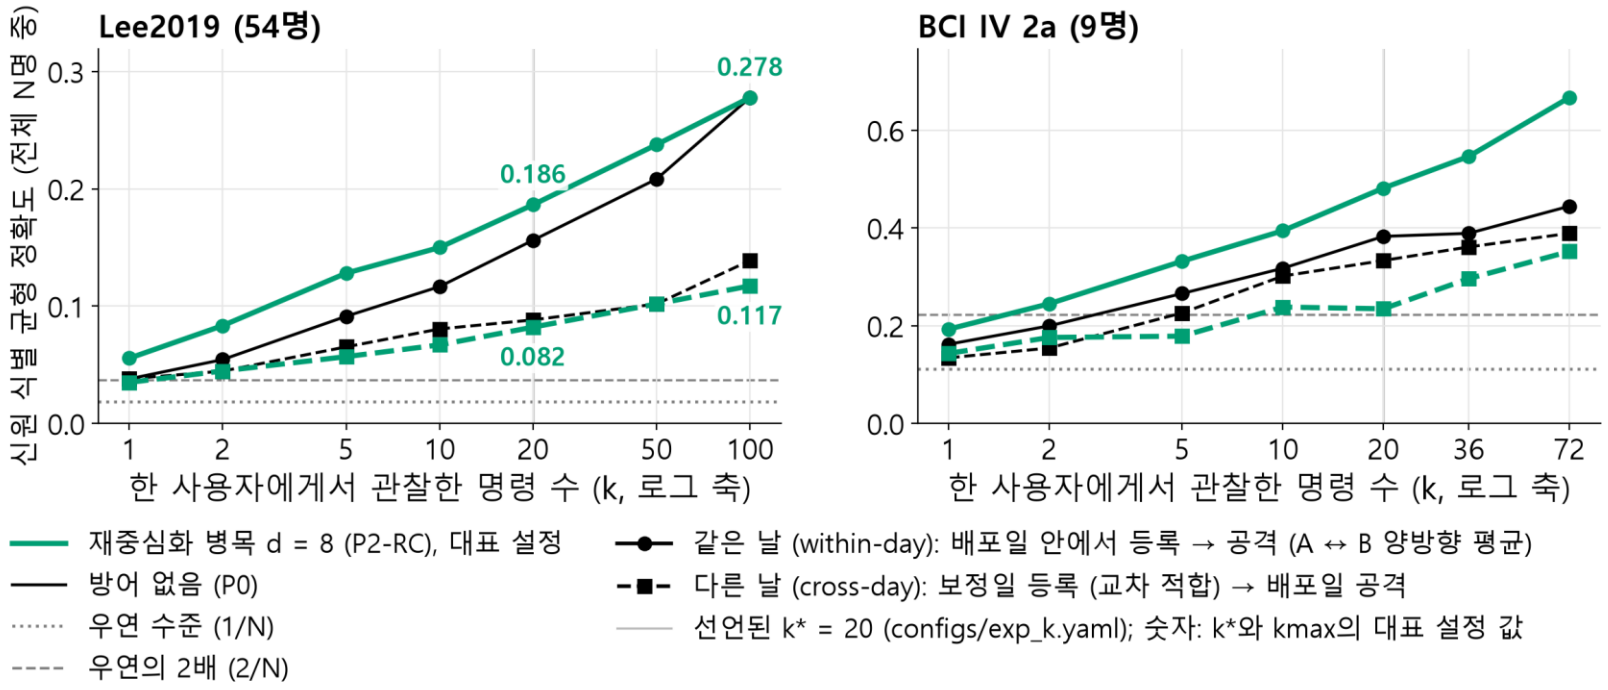
1.34% → 92.7%

기준 세션 공격(다른 날, 논문 2.4%)
→ 배포 라벨 5개(같은 날)
Holm $p = 4.5 \times 10^{-35}$

명령만 보내도 관찰이 쌓이면 노출이 커지지만, 54명 확증 검정 C3는 지지되지 않았다

탐색적 K: 해독된 명령이 쌓일수록 사용자가 드러난다

Lee2019, P2-RC, τ = 0.8: 같은 날 0.186 (k = 20) → 0.278 (k = 100), 다른 날 0.082 (k = 20) → 0.117 (k = 100)
Bayes 공격자 4종 (범주형·Markov, 목표 미인지·인지: cat_*, markov_*) 중 최강 (frontier.csv 정의), seed 3개 평균



자료: results/exp_k/identity_curves.csv (family_set = bayes, defence = none, metric = nway, τ = 0.8)

탐색적

같은 날 | 확증 검정

C3 · Lee2019 54명

지지 안 됨

τ = 0.5, 명령 20개에서 0.085
보정 뒤 Holm p = 0.21

같은 날 | 탐색 K

P2-RC d = 8, τ = 0.8

0.186 → 0.278

명령 20개 → 100개

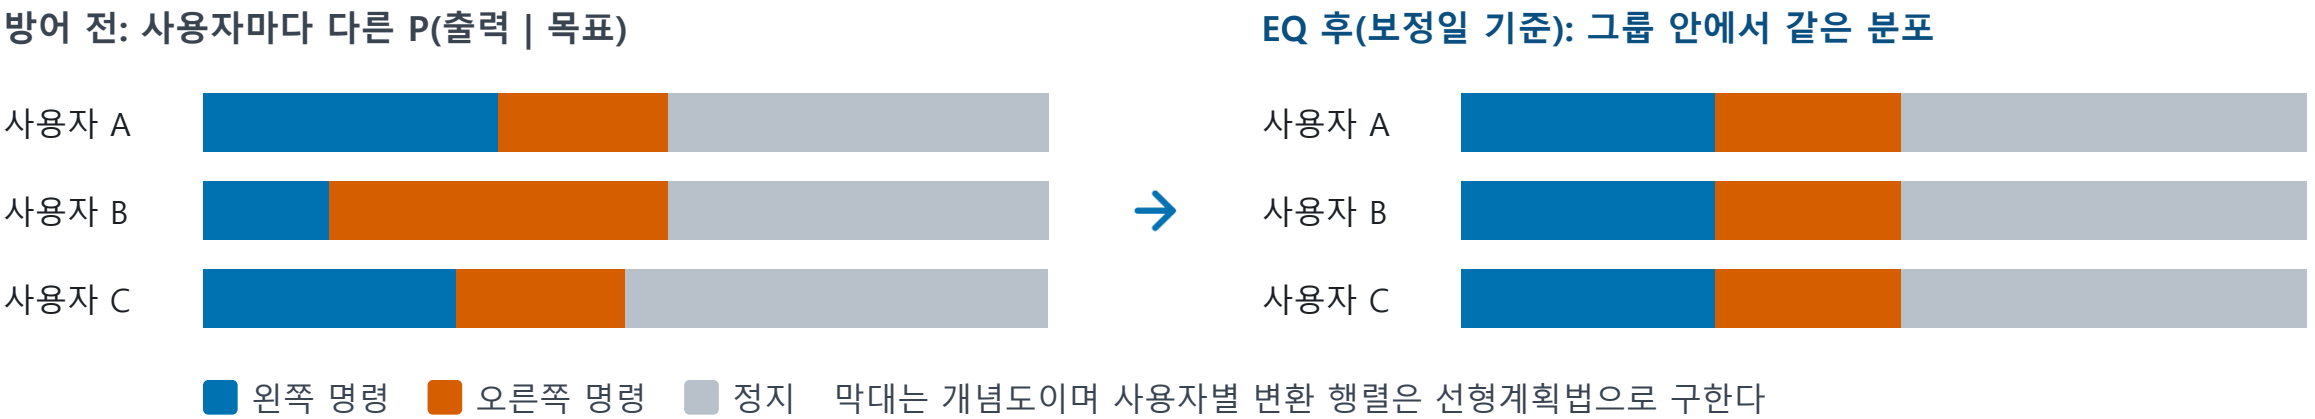
다른 날 | 탐색 K

같은 설정, 보정일로 등록

0.082 → 0.117

우연 0.019, Bayes 공격자 중 최강

EQ는 보정일 기준으로 한 그룹 안 사용자들의 출력 분포를 같게 만들어, 그룹 안에서만 신원을 숨긴다



g = 전체 54명을 한 그룹으로

유용성 0.000 · 정지 1.000

모두를 같게 하면 항상 정지만 남는다

g = 3 (54명 = 3명 × 18그룹)

유용성 0.108 · 정지 0.773

방어 없음: 유용성 0.075 · 정지 0.648

드러나는 것

그룹 소속

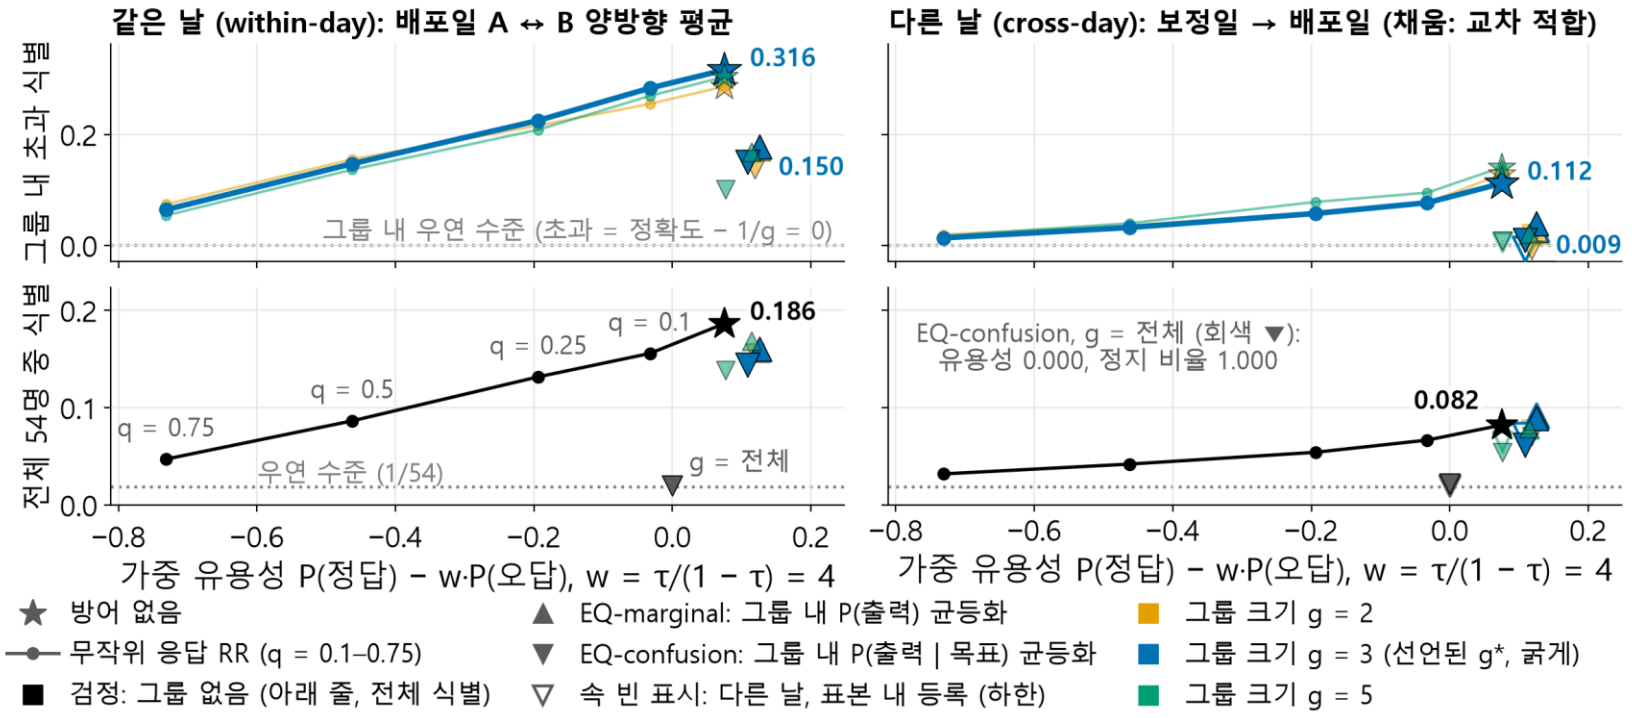
EQ는 그룹 안의 구분만 막는다

탐색 K · Lee2019 P2-RC d = 8, τ = 0.8, 배포일. 유용성 = P(정답) − w·P(오답). EQ의 유용성 차이는 방어 없는 규칙 대비이며 재보정 효과가 섞여 있다.
사전등록 추정치 · Yang2025 1일차 개발 자료(같은 날, τ* = 0.60): 재보정만 한 경우 대비 EQ 비용 0.015 (구간 −0.002–0.032)

EQ의 보장은 맞춘 보정일에만 정확했고, 배포일에 등록한 공격자에게는 노출이 남았다

탐색적 K: 무작위 응답(RR) 대 그룹 균등화 해독(EQ), 대표 설정

g = 3, EQ-confusion: 그룹 내 초과 같은 날 0.316 → 0.150, 다른 날 0.112 → 0.009; 가중 유용성 0.075 → 0.108
Lee2019 (54명), 재중심화 병목 P2-RC, τ = 0.8 (w = 4), k = 20, Bayes 공격자 4종 중 최강



자료: results/exp_k/frontier.csv (lee2019, P2-RC_d8, τ = 0.8; k = 20 columns); users and chance: results/exp_k/identity_curves.csv

탐색적

다른 날 탐색

보정일로 등록, 배포일 공격

0.112 → 0.009

그룹 내 초과 식별, 명령 20개, g = 3

같은 날 탐색

배포일 안에서 등록하고 공격

0.316 → 0.150

절반 가까이 남는다

같은 날 탐색

남은 노출 0.138의 분해(별도 계산)

0.020 + 0.017 + 0.100

측정 바닥, 유한한 보정 데이터, 같은 날 시뮬레이션 밖의 몫

사전등록 M · Yang2025 51명

새 사용자 51명 검증은 결과를 보기 전에 봉인하고 제3자 시각 인증을 받았다

1. **1일차만 열고 설계**
   해독기, 임계값, 게이트를 1일차 안에서만 정한다
2. **봉인 4: 커밋 e88154c, 태그 seal-4**
   계획, 코드, 설정, 1일차 선택을 고정한다
3. **FreeTSA 시각 인증**
   토큰 시각 2026-11-10 20:26:22 GMT
4. **그다음 2–3일차를 받아 판정**
   봉인된 코드가 봉인과 다르면 실행을 거부한다

판정 가족

M1–M3, Holm α = 0.05

1차 시나리오: 1일차로 등록, 2–3일차 공격 (다른 날)

EQ와 무작위 응답(RR)

사전등록한 추정치, 판정 없음

M3 검정력 (같은 날 효과 중 다른 날에 남는 비율)

보존율	검정력, α = 0.05	검정력, α/3
0.35	0.47	0.29
0.55	**0.85**	0.69
0.70	0.96	0.90

사전등록 M · 결과

새 사용자 51명, 다른 날: 사전등록한 주장 3개 중 2개가 지지됐다

다른 날 | 확증 M1–M3 | 1일차로 등록, 2–3일차 공격 · Holm α = 0.05 · 독립 재계산 통과

주장	사전등록한 문구 · 판정 기준	결과	판정
M1	원 특징의 다른 날 식별(사전등록상 저위험 재현) 기준: 최강 공격자 평균 재현율 > 10/51 (3종 Bonferroni)	로지스틱 공격자 재현율 0.345 대 10/51 = 0.196 Holm p = 0.014	지지
M2	독립 공격자와 공동 학습 head의 격차가 0보다 크고 관측값이 0.10 이상 기준: P3 λ = 1, 관측 격차 ≥ 0.10인 공격자만 검정	격차 0.093–0.096: 모두 0보다 크지만 봉인한 관측 하한 0.10 미만 → 검정한 공격자 없음, 규칙상 p = 1	지지 안 됨
M3	본인의 순위가 우연보다 높고 명령 1개일 때보다 높다 기준: P2-RC d = 8, τ* = 0.60, 명령 50개, 순위 > 0.5	순위 0.649 대 명령 1개 0.538, Holm p = 1.1×10^{-4} 순위는 식별률이 아니다: top-1 0.061	지지

EQ와 무작위 응답(RR): 사전등록한 추정치, 판정 없음.

EQ 격자(g = 3): τ* 명령 50개에서 공격자 4종 중 3종이 K와 같은 방향

명령 20개에서는 감소가 0과 구별되지 않음(1종은 막을 노출도 구별되지 않음) · τ 0.5에서는 막을 노출이 구별되지 않음 (백업 B8)

결과마다 쓸 문장은 결과를 보기 전에 결정 로그에 고정했다 (커밋 7b14cee). C3는 지지 안 됨으로 남는다

제안과 한계

보호를 주장하려면 여섯 가지를 확인해야 하고, 이 결과에는 분명한 한계가 있다

확인할 것

1. **독립 공격자로 다시 공격한다**
   함께 학습한 식별기의 점수는 증거가 아니다
2. **배포 기간 라벨을 가진 공격자를 시험한다**
   라벨 수별 재식별 곡선을 함께 보고한다
3. **같은 날과 다른 날을 모두 보고한다**
   모든 수치에 등록한 날을 적는다
4. **우연 수준과 사용자 수를 함께 밝힌다**
   공격자의 실패를 익명화로 표현하지 않는다
5. **단순한 기준선과 비교한다**
   과제 병목과 재중심화를 먼저 이겨야 한다
6. **관찰 길이를 늘리고, 채점 전에 봉인한다**
   메시지 하나 기준의 수치는 노출을 과소평가한다

한계

- **닫힌 집합 식별**
  9명, 54명, 51명 안에서 누구인지 고르는 문제다
- **재생 실험**
  로봇팔은 기록된 뇌파를 재생해 움직였다
- **공격자 범위**
  더 강한 공격자가 있을 수 있어 수치는 하한이다
- **탐색 결과**
  K, R, D, E, G는 이미 본 데이터를 다시 썼다
- **자기 증명**
  봉인 1–3과 접근 기록은 제3자 증명이 없다
- **EQ 보장의 범위**
  맞춘 보정일 혼동 행렬에만 정확하고, 그룹 소속은 드러난다

정리

BCI 전송물의 신원 노출과 방어 효과는 공격자가 어느 날의 기록으로 등록하느냐에 따라 달라지므로, 같은 날 수치 하나로는 위험도 보호도 주장할 수 없다

1 같은 날 0.994였던 식별이 다른 날 등록에서는 0.520이었다. 낮아졌지만 우연 0.019보다 훨씬 높다

2 두 함정은 54명의 같은 날 조건에서 확증됐다(함정 1의 다른 날 격차 19.9%p는 사전등록 추정치).
EQ의 보장은 맞춘 날에만 정확했다 (탐색)

3 다른 날에는 M1·M3만 재현됐다. M2는 같은 날 조건의 결과로 남는다

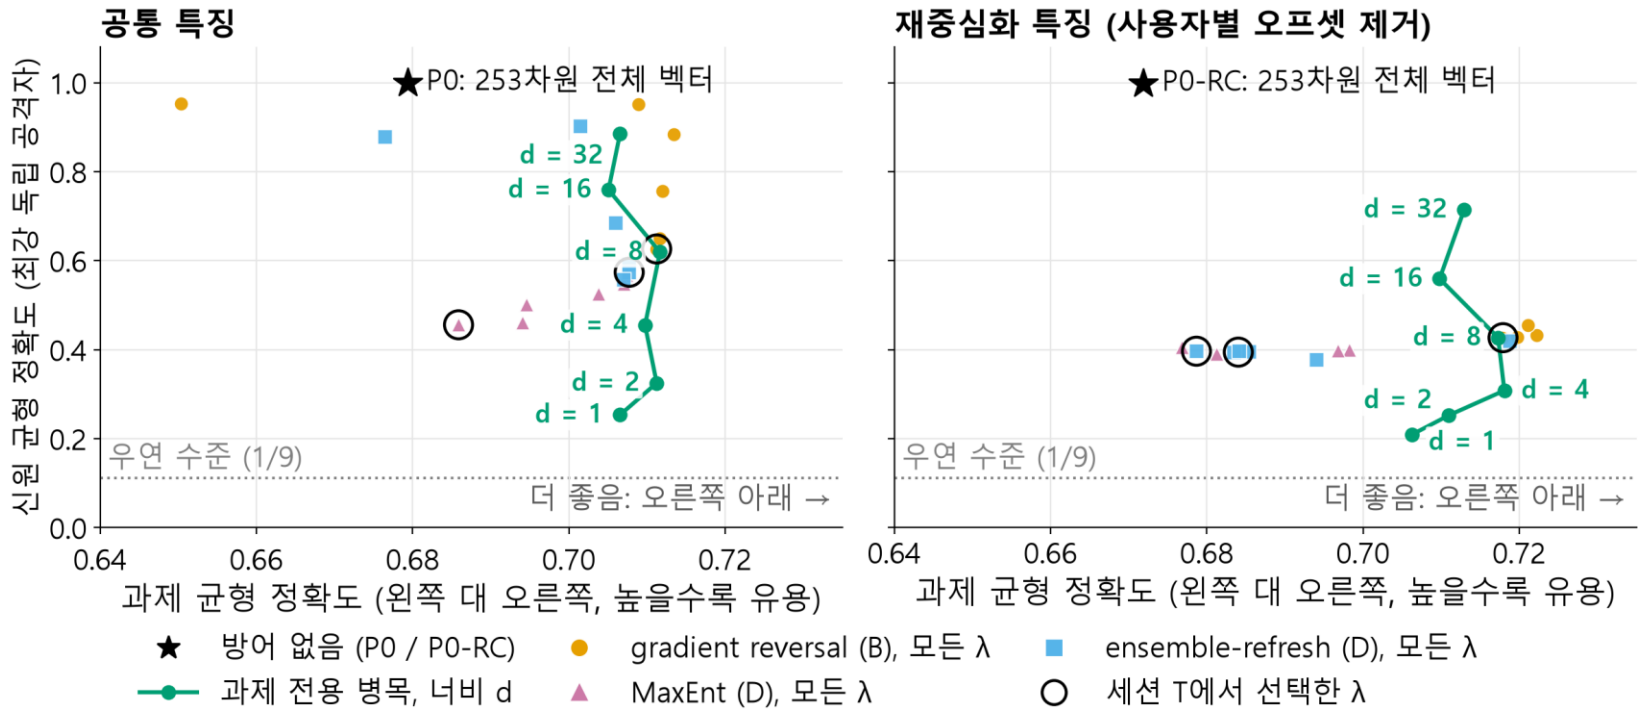
GitHub 저장소 · CI | 기술보고서 | 인터랙티브 웹 데모 | 한국어 해설서

감사합니다. 질문을 받겠습니다

좁은 과제 병목이 노출을 가장 많이 줄였지만 우연 수준까지는 아니다 (같은 날)

어떤 적대적 방어도 좁은 과제 전용 병목을 넘지 못했다

유용성을 유지한 가장 낮은 식별: 1차원 병목 (공통 0.25, 재중심화 0.21) — 여전히 우연의 약 2배



자료: results/exp_d/tradeoff.csv (과제 전용, MaxEnt, ensemble, P0), results/exp_b/tradeoff.csv (GRL)

B GRL 확증 · D 탐색적

같은 날 탐색 D

d = 1, BCI IV 2a 9명

식별 0.25

과제 정확도 0.71

같은 날 사전등록 추정치

d = 1, Lee2019 54명

식별 0.057

과제 정확도 0.70 · seed 3개

탐색

적대적 학습 3종

gradient reversal, MaxEnt, ensemble refresh 모두 이 기준선을 넘지 못했다

54명 확증 재현에서 사전등록한 주장 4개 중 3개가 지지됐다



백업 B3 · 연구 무결성

지지되지 않은 가설과 실행 중 문제도 그대로 보고했다

사전등록 가설	결과	판정
H1 접공간 해독기가 CSP보다 낫다, 보정 1 run	0.689 대 0.669, p = 0.10	**지지 안 됨**
H2 적대 학습(P3)이 과제 전용 병목(P2)보다 노출을 5%p 이상 더 줄인다(공통·재중심화 두 계열 모두)	선택된 λ = 0.01, 차이 없음	**지지 안 됨**
C3 54명에서 명령 관찰이 길수록 노출이 커진다	명령 20개 0.085, Holm p = 0.21	**지지 안 됨**

봉인 커밋 1–3

`6ab5668, b216b7d, 9757c3f`

봉인 해시 검증

봉인과 다르면 평가 데이터를 열지 않는다

실패 기록 보존

메모리 부족으로 멈춘 실행도 남기고 같은 분석을 재실행

백업 B4 · MLP 수렴 (탐색 R)

수렴하지 않은 MLP 45개를 모두 다시 적합해도 확증 판정은 바뀌지 않았다

같은 날 | 탐색 R | Lee2019 54명 · 공격자 값은 주 시나리오(같은 날)

주장 · 값	봉인 적합 반복 500회	재적합 반복 20000회	판정
C1 · 독립 공격자와 함께 학습한 식별기의 격차	0.4744	0.4584	**지지 그대로**
C2 · P0 대비 P2-RC d = 8의 식별 감소	0.6538	0.6599	**지지 그대로**
C3 · 명령 20개, MLP 공격자의 식별	0.0763	0.0767	**지지 안 됨 그대로**

봉인 판정(C1·C2 지지, C3 지지 안 됨)은 MLP 수렴 여부에 좌우되지 않았다.
재적합 예측으로 L의 판정 코드를 다시 실행했다. C4에는 수렴하지 않은 MLP가 없었다

탐색 R

재적합 45개 (반복 20000회)

42개 수렴

C3 적합 269·278·280은 끝내 미수렴,
그 예측을 그대로 사용
봉인 적합 45/45를 먼저 똑같이 재현

같은 날 | 탐색 R

적합별 균형 정확도 변화

최대 2.6%p

C1 적합 1개

봉인 규칙 (반복 500회)

286/586 미수렴

확증 검정에 들어간 적합 중 45/85. 봉인 규칙대로
예측을 유지했다

EQ는 그룹 안 혼동 행렬을 같게 하는 제약 아래 가중 유용성을 최대화한다

목적

사용자 평균 가중 유용성 P(정답 방향) − w·P(반대 방향)을 최대화한다

$w = \tau/(1-\tau)$, $\tau = 0.8$이면 $w = 4$

제약 (EQ-confusion)

그룹 안 모든 사용자 u에 대해 $\Sigma_c C_u(y, c)\, M_u(c, o) = Q(y, o)$

항상 정지가 언제나 가능해서 LP는 항상 풀린다

보장과 가정

LP가 받은 혼동 행렬 추정치(평활된 보정일 수)에 대해서만 정확하다

시행마다 독립 후처리, 목표 순서가 사용자와 무관, 시행 간 조건부 독립을 가정한다

그룹 소속은 드러난다: 최대 log2(N/g) 비트

유한한 보정 데이터와 보정일 → 배포일 변화가 잔여 노출을 남긴다

최적성은 쌍대 간격으로 인증한다

정보량으로 보면 EQ는 그룹 안 신원 정보만 줄이고 전체 신원 정보는 거의 그대로 둔다

배포일 하루 안의 명령 1개당 정보 (같은 날)	방어 없음	EQ g = 3
과제 정보 (bits)	0.221	0.158
정보 전송률 ITR (bits/분)	1.02	0.73
신원 정보, 54명 전체 (bits)	0.467	0.452
신원 정보, 그룹 안 g = 3 (bits)	0.198	**0.072**

탐색 K · Lee2019 P2-RC d = 8, τ = 0.8 · 목표 인지 공격자 기준. 순열 영점 0.014는 방어 없음·54명 전체 행의 값이다. 그룹 안 정보가 줄어도 전체 정보가 남는 것은 그룹 소속이 드러나기 때문이다

봉인 4의 시각 인증은 공개 도구 OpenSSL로 누구나 다시 확인할 수 있다

```
openssl ts -verify -digest ecc7e565…81c6 -in seal4.tsr -CAfile cacert.pem -untrusted tsa.crt
→ Verification: OK
```

봉인 커밋	`e88154c6f0b3d1a7887f2368763808fc91d9a81a`
지문 (커밋 ID의 SHA-256)	`ecc7e565…81c6`
토큰 시각	2026-11-10 20:26:22 GMT
검증 도구와 결과	OpenSSL 3.5.7, 종료 코드 0, 검증 시각 20:26:36 UTC
한계	토큰은 커밋 시각만 증명한다. 다운로드 기록은 자기 증명이다

백업 B8 · M의 EQ 추정치 (판정 없음)

새 51명에서 EQ 추정치는 칸 하나가 아니라 격자 전체로 읽고, 유용성 비교에는 단서가 붙는다

다른 날 | 사전등록 추정치 그룹 안 초과 식별, g = 3, 1일차로 등록

τ · 명령 수	범주형 목표 모름	범주형 목표 앎	Markov 목표 모름	Markov 목표 앎
τ* = 0.60 명령 50개	감소가 0과 구별 안 됨	**K와 같은 방향**	**K와 같은 방향**	**K와 같은 방향**
τ* = 0.60 명령 20개	막을 노출 구별 안 됨	감소가 0과 구별 안 됨	감소가 0과 구별 안 됨	감소가 0과 구별 안 됨
τ = 0.5 명령 50개	막을 노출 구별 안 됨	막을 노출 구별 안 됨	막을 노출 구별 안 됨	막을 노출 구별 안 됨
τ = 0.5 명령 20개	막을 노출 구별 안 됨	막을 노출 구별 안 됨	막을 노출 구별 안 됨	막을 노출 구별 안 됨

K와 같은 방향: 1일차 → 2–3일차 감소 구간이 0을 제외하고, EQ 자체의 초과 식별도 2일차 ↔ 3일차 또는 같은 날 반분에서 0을 제외

감소가 0과 구별 안 됨: 막을 노출은 구별됐지만 EQ의 감소는 0과 구별되지 않았다
막을 노출 구별 안 됨: EQ 효과를 말할 수 없다

예시(τ*, 명령 50개, 범주형 목표 앎): 방어 없음 0.101 [0.022, 0.181] → EQ −0.008 [−0.058, 0.042], 감소 0.109 [0.007, 0.211]

유용성 단서 (2–3일차, τ* = 0.60)

방어 없음 가중 유용성 −0.041 [−0.086, 0.004]는 0을 포함한다 (w = 1.5).
순진행 P(정답) − P(오답)은 +0.073 [0.039, 0.106]

정지율 0.723(1일차, 교차 적합 모델)과 0.473(2–3일차, 최종 모델)은 다른 모델의 값이다. 1일차에 맞춘 τ 규칙은 이후 날에 덜 멈추고 더 틀린다 (오답 0.092 → 0.227)

EQ의 프라이버시 비용은 순진행 기준 +0.022 [0.012, 0.032]다. 가중 유용성 기준 −0.009 [−0.026, 0.008]은 0을 포함한다

해독기가 해롭다거나 EQ의 프라이버시가 공짜라고 읽지 않는다